

# Séries Temporais

## Definição

Uma série temporal é uma sequência de dados ou observações registradas em momentos consecutivos no tempo, geralmente em intervalos regulares, que refletem a evolução de uma variável ao longo do tempo. Ela permite analisar padrões, tendências, ciclos e sazonalidades para entender o comportamento passado e fazer previsões futuras.

## Exemplos

- Vendas diárias de uma loja.
- Temperatura média mensal de uma cidade.
- Cotação diária de ações na bolsa.

## Estrutura

**Observações (yt):** Valores medidos em momentos  $t$ .

**Tempo (t):** Pode ser diário, semanal, mensal, anual ou em intervalos irregulares.

## Utilidade e Quando Usar Séries Temporais

Séries temporais são úteis em cenários onde os dados variam ao longo do tempo e existe a necessidade de entender padrões, realizar análises ou prever eventos futuros. Elas são empregadas em diversas áreas devido à sua capacidade de capturar tendências, sazonalidades e dependências temporais.

A análise de séries temporais é essencial para previsão, identificação de padrões, monitoramento, tomada de decisão estratégica e otimização de processos.

A previsão permite estimar valores futuros com base em dados históricos, sendo útil para demandas de estoque, vendas, produção de energia e preços de mercado. Já a análise de padrões identifica tendências, sazonalidades e ciclos, auxiliando no entendimento de variações de vendas, padrões climáticos e comportamento do consumidor.

O monitoramento detecta anomalias em tempo real, como falhas em máquinas, fraudes financeiras e variações no tráfego de redes. Na tomada de decisão

estratégica, essas informações ajudam no planejamento de campanhas, precificação dinâmica e infraestrutura urbana.

Por fim, a otimização permite ajustar processos automaticamente, como controlar a produção industrial, gerenciar o consumo de energia e otimizar transportes públicos.

## **Componentes de Séries Temporais**

As séries temporais podem ser decompostas em quatro componentes principais:

### **1. Tendência (Trend)**

Representa o movimento de longo prazo na série. Exemplo: Crescimento consistente no número de vendas ao longo dos anos.

### **2. Sazonalidade (Seasonality)**

Padrões que se repetem em intervalos regulares de tempo. Exemplo: Aumento de vendas no Natal.

### **3. Ciclo (Cycle)**

Flutuações que ocorrem devido a fatores econômicos ou outros ciclos (não tem a ver com o tempo). Exemplo: Alta e baixa de um mercado financeiro em períodos não fixos.

### **4. Resíduo (Noise)**

Variação aleatória ou irrelevante na série. Exemplo: Pequenas flutuações inesperadas em vendas diárias.

## **Tipos de Séries Temporais**

### **1. Univariada**

Contém apenas uma variável observada ao longo do tempo. O foco é entender e prever essa única variável com base em seus próprios valores passados. Exemplo: Preço diário de uma ação, temperatura média mensal, vendas de um produto ao longo do ano.

### **2. Multivariada**

Envolve múltiplas variáveis inter-relacionadas, analisadas simultaneamente. Essas variáveis podem influenciar umas às outras, tornando a modelagem mais complexa. Exemplo: Preço de uma ação

considerando também taxas de juros e volume de negociação, previsão de demanda levando em conta fatores climáticos e promoções.

## Estacionaridade

Um conjunto de dados estacionário é aquele cujas propriedades estatísticas não mudam ao longo do tempo. Isso significa que a média, a variância e a auto covariância do processo são constantes. Em outras palavras, uma série temporal estacionária não apresenta tendências ou sazonalidades de longo prazo, tornando-a mais previsível e mais fácil de modelar.

## Modelos e Técnicas de Análise

### Modelos Estatísticos

#### 1. Média Móvel (Moving Average)

A Média Móvel suaviza flutuações em uma série temporal, facilitando a identificação de tendências. Ela calcula a média de um número fixo de valores anteriores, eliminando variações aleatórias.

#### 2. ARIMA (AutoRegressive Integrated Moving Average)

O modelo ARIMA combina três componentes principais para modelar séries temporais:

**AR (AutoRegressive):** Usa valores passados da própria série para prever futuros.

**I (Integrated):** Aplica diferenciação para tornar a série estacionária.

**MA (Moving Average):** Modela os erros da previsão baseando-se em valores passados.

O ARIMA é indicado para séries temporais estacionárias ou que podem ser transformadas em estacionárias. Ele é representado como **ARIMA(p, d, q)**, onde:

**p** = Número de defasagens na parte autoregressiva.

**d** = Número de diferenciações para tornar a série estacionária.

**q** = Número de termos de média móvel.

**Exemplo de Aplicação:** Previsão de demanda por produtos ou previsão de inflação.

### 3. **SARIMA (Seasonal ARIMA)**

O **SARIMA** é uma extensão do ARIMA que incorpora sazonalidade, ou seja, padrões que se repetem periodicamente. Ele adiciona quatro novos parâmetros para capturar variações sazonais:

**P** = Ordem da parte autoregressiva sazonal.

**D** = Diferenciação sazonal necessária.

**Q** = Ordem da média móvel sazonal.

**S** = Período da sazonalidade (exemplo: 12 para dados mensais).

O modelo é representado como **SARIMA(p, d, q) × (P, D, Q, S)**.

**Exemplo de Aplicação:** Previsão de vendas sazonais, como consumo de energia elétrica ao longo do ano.

## **Etapas Práticas para Análise de Séries Temporais**

### **1. Importar e Visualizar os Dados**

A visualização de dados é uma etapa essencial na análise de séries temporais, pois permite identificar padrões, tendências, sazonalidade e anomalias antes da modelagem. Algumas das principais técnicas incluem:

**Gráfico de Linha:** A forma mais comum de visualização, exibindo a evolução dos dados ao longo do tempo. Ajuda a detectar tendências e padrões sazonais.

**Histogramas e Boxplots:** Úteis para analisar a distribuição dos dados e identificar outliers.

**Autocorrelação (ACF) e Parcial (PACF):** Mostram como os valores passados influenciam os valores futuros, auxiliando na escolha de modelos ARIMA/SARIMA.

**Decomposição de Série Temporal:** Separa os componentes da série em tendência, sazonalidade e resíduo, facilitando a interpretação.

**Heatmaps e Gráficos de Dispersão:** Podem ser usados para visualizar padrões sazonais ou relações entre múltiplas variáveis em séries temporais multivariadas.

## 2. Analisar a Estacionaridade

### Visualização Gráfica

**Gráfico de Linha:** Se houver uma tendência crescente/decrescente ou padrões sazonais evidentes, a série pode não ser estacionária.

**Rolling Statistics:** Calcular e plotar a média e a variância em janelas móveis para ver se se mantêm constantes.

### Testes Estatísticos

#### Teste de Dickey-Fuller Aumentado (ADF)

Hipótese nula ( $H_0$ ): A série tem raiz unitária (não estacionária).

Hipótese alternativa ( $H_1$ ): A série é estacionária.

Se o p-valor for menor que 0,05, rejeitamos  $H_0$  e concluímos que a série é estacionária.

#### Teste KPSS (Kwiatkowski-Phillips-Schmidt-Shin)

Hipótese nula ( $H_0$ ): A série é estacionária.

Hipótese alternativa ( $H_1$ ): A série não é estacionária.

Se o p-valor for menor que 0,05, rejeitamos  $H_0$ , indicando que a série não é estacionária.

#### Teste de Phillips-Perron (PP)

Similar ao ADF, mas mais robusto a heterocedasticidade.

### Função de Autocorrelação (ACF) e Autocorrelação Parcial (PACF)

Se a ACF decai lentamente em vez de cair rapidamente para zero, a série pode ser não estacionária.

### Como Tornar uma Série Estacionária?

Se a série não for estacionária, pode-se aplicar transformações para estabilizar suas propriedades:

**Diferenciação:** Subtrair o valor anterior do atual ( $Y_t - Y_{t-1}$ ) para remover tendências.

**Transformação Logarítmica ( $\log Y_t$ ):** para estabilizar a variância.

**Diferenciação Sazonal:** Para séries com sazonalidade, subtrair valores do mesmo período anterior ( $Y_t - Y_{t-s}$ ).

**Remover Tendência com Modelos de Regressão:** Ajustar e remover uma tendência linear ou polinomial.

$Y_t$  representa o valor da série temporal no instante  $t$ . Ou seja, é o valor observado no tempo  $t$ .

$S$  representa a sazonalidade da série, ou seja, o número de períodos após os quais os padrões se repetem.

### 3. Decomposição

A decomposição de séries temporais é uma técnica que separa a série em diferentes componentes para facilitar a análise e a modelagem. Isso permite entender melhor as tendências, identificar padrões sazonais e remover ruídos. Podendo ser dividida em Tendência, Sazonalidade e Resíduo.

#### 1. Decomposição Aditiva

Quando os componentes são somados:

$$Y_t = \text{Trend}_t + \text{Seasonal}_t + \text{Residual}_t$$

Usada quando a **amplitude da sazonalidade é constante** ao longo do tempo.

**Exemplo:** Temperatura média diária ao longo do ano.

#### 2. Decomposição Multiplicativa

Quando os componentes são multiplicados:

$$Y_t = \text{Trend}_t \times \text{Seasonal}_t \times \text{Residual}_t$$

Aplicada quando a **sazonalidade varia em intensidade** conforme a tendência cresce ou diminui.

**Exemplo:** Receita de uma empresa, onde picos sazonais aumentam à medida que a empresa cresce.

#### 4. Modelagem

Escolher e ajustar o modelo apropriado (ARIMA, SARIMA, LSTM, Prophet, etc.).

#### 5. Avaliação

Ao trabalhar com séries temporais, a separação dos dados deve ser feita de forma **sequencial**, mantendo a ordem cronológica. Diferente de problemas comuns de aprendizado de máquina, onde a divisão pode ser aleatória, em séries temporais isso comprometeria a capacidade preditiva do modelo.

##### Como Dividir os Dados?

A abordagem mais utilizada é:

**Conjunto de Treino:** Parte inicial dos dados, usada para ajustar o modelo.

**Conjunto de Teste:** Últimos períodos da série, utilizados para avaliar a performance.

#### Métricas de Avaliação para Séries Temporais

Depois de treinar o modelo, ele precisa ser avaliado com métricas que quantificam o erro das previsões em relação aos valores reais. As mais utilizadas são:

##### 1. RMSE (Erro Quadrático Médio - Root Mean Squared Error)

Mede a diferença média entre valores reais e previstos, penalizando mais os erros grandes:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - p_i)^2}$$

Valores menores indicam previsões mais precisas.

Penaliza fortemente erros grandes devido à elevação ao quadrado.

## 2. MAE (Erro Absoluto Médio - Mean Absolute Error)

Mede a média dos erros absolutos, sem dar peso maior para erros grandes:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - p_i|$$

Fácil de interpretar, pois está na mesma unidade dos dados.

Não amplifica tanto os erros maiores, diferente do RMSE.

## 3. MAPE (Erro Percentual Médio Absoluto - Mean Absolute Percentage Error)

Expressa o erro médio em termos percentuais, o que facilita a interpretação:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - p_i}{y_i} \right|$$

Útil para comparar previsões em diferentes escalas de valores.

Problemático quando  $Y_i$  se aproxima de zero, pois pode gerar distorções.

## Desafios em Séries Temporais

### 1. Não-estacionaridade

Séries temporais que possuem média ou variância variando ao longo do tempo.

Solução: Transformações (diferenciação, logaritmos).

### 2. Dados Perdidos (Missing Data)

Dados ausentes podem prejudicar a análise.

Solução: Interpolação ou preenchimento com valores estimados.



### 3. **Séries Curta**

Poucos dados dificultam a identificação de padrões.

Solução: Adicionar variáveis externas ou usar modelos que lidem bem com pequenos conjuntos de dados.

### 4. **Sazonalidades Complexas**

Séries com múltiplos padrões sazonais podem ser difíceis de modelar.